

BÁO CÁO THÍ NGHIỆM: PHÂN LOẠI LOÀI HOA IRIS BẰNG NAIVE BAYES

Sinh viên: Phan Tự Trường

MSSV: 20221889

Ngày thực hiện: 11/11/2025

1. Thử nghiệm: Phân loại loài hoa Iris

Bộ dữ liệu **Iris** là một trong những tập dữ liệu kinh điển trong học máy, được giới thiệu bởi **Ronald Fisher (1936)**.

Dữ liệu mô tả ba loài hoa *Iris Setosa*, *Iris Versicolor* và *Iris Virginica* thông qua bốn đặc trưng hình thái học:

STT	Tên đặc trưng	Mô tả
1	Sepal length	Chiều dài đài hoa (cm)
2	Sepal width	Chiều rộng đài hoa (cm)
3	Petal length	Chiều dài cánh hoa (cm)
4	Petal width	Chiều rộng cánh hoa (cm)

Nguồn dữ liệu:

<https://www.kaggle.com/code/anshigupta01/iris-flower-classification>

2. Phương pháp: Lập luận xác suất với Naive Bayes

Phương pháp **Naive Bayes** dựa trên **định lý Bayes**, mô tả mối quan hệ giữa xác suất có điều kiện của một lớp và các đặc trưng quan sát.

Công thức cơ bản:

$$P(C_k | X) = [P(X | C_k) * P(C_k)] / P(X)$$

Trong đó:

- $P(C_k | X)$: xác suất mẫu X thuộc lớp C_k (xác suất hậu nghiệm)
- $P(X | C_k)$: xác suất quan sát X khi biết lớp C_k (xác suất khả năng)
- $P(C_k)$: xác suất tiên nghiệm của lớp C_k
- $P(X)$: xác suất tổng thể của mẫu X

Với dữ liệu liên tục như Iris, ta dùng **Gaussian Naive Bayes**, giả định rằng mỗi đặc trưng tuân theo phân phối chuẩn (Gaussian):

$$P(x_i | C_k) = (1 / \sqrt{2 * \pi * \sigma^2(C_k)}) * \exp(- (x_i - \mu(C_k))^2 / (2 * \sigma^2(C_k)))$$

Trong đó:

- $\mu(C_k)$: giá trị trung bình của đặc trưng trong lớp C_k
- $\sigma^2(C_k)$: phương sai của đặc trưng trong lớp C_k

3. Tập học

Tập dữ liệu có 150 mẫu, chia đều cho 3 lớp (50 mẫu/lớp):

- Iris-setosa
- Iris-versicolor
- Iris-virginica

Dữ liệu được chia theo phương pháp **Hold-out**:

$$|D_{\text{train}}| = (2/3)|D| = 100 \text{ mẫu}$$

$$|D_{\text{test}}| = (1/3)|D| = 50 \text{ mẫu}$$

4. Kỹ thuật đánh giá: Hold-out

Dữ liệu được chia ngẫu nhiên thành 2 phần:

- Tập huấn luyện (Train): 100 mẫu (~2/3)
- Tập kiểm tra (Test): 50 mẫu (~1/3)

Các chỉ số đánh giá gồm:

- Accuracy (độ chính xác)
- Precision, Recall, F1-score
- Ma trận nhầm lẫn (Confusion Matrix)

5. Tối ưu: Lựa chọn tham số cân bằng xác suất

Để đảm bảo mô hình không thiên lệch về lớp nào, ta đặt:

$$\text{priors} = [1/3, 1/3, 1/3]$$


Tức là mỗi lớp có xác suất tiên nghiệm bằng nhau.

Điều này đặc biệt hữu ích khi dữ liệu mất cân bằng.

Với Iris, các lớp vốn đã cân bằng, nên kết quả không thay đổi nhiều.

6. Kết quả minh họa

Độ chính xác (Accuracy): 92.0%



```
Độ chính xác (Accuracy): 92.0 %

Báo cáo phân loại:
              precision    recall  f1-score   support

   setosa         1.00        1.00        1.00        16
  versicolor    0.84         0.94         0.89        17
   virginica     0.93         0.82         0.88        17

 accuracy          0.92         0.92         0.92        50
  macro avg       0.93         0.92         0.92        50
 weighted avg     0.92         0.92         0.92        50
```

Báo cáo chi tiết theo từng lớp:

Lớp (Loài hoa)	Precision	Recall	F1-Score	Số mẫu (Support)
Setosa	1.00	1.00	1.00	16
Versicolor	0.84	0.94	0.89	17
Virginica	0.93	0.82	0.88	17
Trung bình (macro avg)	0.93	0.92	0.92	50
Trung bình có trọng số (weighted avg)	0.92	0.92	0.92	50

Phân tích chi tiết:

- **Setosa:**
Mô hình nhận dạng hoàn hảo (precision, recall, F1-score đều bằng 1.00).
Các đặc trưng của Setosa tách biệt rõ ràng so với hai lớp còn lại.
- **Versicolor:**
Có 1 số mẫu bị nhầm sang Virginica (Recall = 0.94, F1 = 0.89).
Cho thấy ranh giới giữa Versicolor và Virginica có phần giao nhau.
- **Virginica:**
Độ chính xác tốt (Precision = 0.93) nhưng bị giảm Recall (0.82).
Một số mẫu Virginica bị nhầm thành Versicolor.



- **Tổng thể:**

Accuracy đạt 92%, macro-F1 = 0.92.

Điều này chứng tỏ mô hình Naive Bayes hoạt động ổn định, mặc dù đôi khi có nhầm lẫn giữa hai loài *Versicolor* và *Virginica*.

Ma trận nhầm lẫn (Confusion Matrix) minh họa:

Thực tế \ Dự đoán	Setosa	Versicolor	Virginica
Setosa	16	0	0
Versicolor	0	14	1
Virginica	0	3	14



7. Kết luận

Kết luận

Thuật toán **Naive Bayes (GaussianNB)** cho kết quả **độ chính xác 92%** trên tập dữ liệu Iris, chứng minh rằng đây là một phương pháp **nhANH, đơn giản nhưng hiệu quả** đối với bài toán phân loại có dữ liệu nhỏ và đặc trưng rõ ràng.

- Mô hình hoạt động **rất tốt với lớp Setosa**, do đặc trưng phân biệt rõ ràng.
- Giữa **Versicolor** và **Virginica** có sự chồng lấn đặc trưng, dẫn đến một vài nhầm lẫn.
- **Tham số priors = [1/3, 1/3, 1/3]** giúp mô hình cân bằng xác suất giữa các lớp, đảm bảo công bằng trong đánh giá.

Nhìn chung, mô hình đạt kết quả **cao và ổn định** với tập dữ liệu Iris, thể hiện hiệu quả của phương pháp **lập luận xác suất Naive Bayes** trong phân loại mẫu sinh học.